SCRAPPING

ANALISIS SENTIMEN PENGGUNA APLIKASI “X” TERHADAP ISU TUMBLER HILANG PADA KERETA KAI MENGGUNAKAN INDOROBERTA

Kelompok 8

ANGGOTA KELOMPOK

Muhammad Fahri Novarian

(1314623014)

Muhamad Alfarizi

(1314623041)

Ariya Zuhdi Ismail

(1314623065)

LATAR BELAKANG

Kasus hilangnya tumbler penumpang KAI yang menjadi viral di media sosial memicu perbincangan luas dan beragam opini dari masyarakat, mulai dari kritik terhadap penumpang yang memviralkan hingga simpati kepada petugas KAI yang dikabarkan terdampak. Fenomena ini menunjukkan bagaimana isu sederhana dapat berkembang menjadi polemik besar ketika melibatkan layanan publik dan ruang digital. Untuk memahami persepsi publik terhadap kasus tersebut, dilakukan analisis sentimen terhadap tweet yang membahas “Tumbler KAI” guna melihat kecenderungan opini masyarakat serta kata-kata yang paling sering muncul dalam diskusi online terkait isu ini.

TUJUAN

1. Mengidentifikasi kecenderungan emosi dan opini publik terhadap kasus viral Tumbler KAI.
2. Mengelompokkan tweet ke dalam kategori sentimen negatif, netral, dan positif.
3. Mengetahui kata-kata atau topik utama yang paling sering muncul dalam setiap kelompok sentimen.
4. Memahami isu apa yang paling memicu reaksi emosional masyarakat.

TAHAPAN PENELITIAN

Scrapping

Pre-processing

Feature Extraction

Klasifikasi

Evaluasi

Analisis Sentimen

SCRAPPING

Pada tahap awal ini, dilakukan pengumpulan data dengan melakukan scrapping dari media sosial X menggunakan tweet harvest yang merupakan tool Node.Js untuk mengambi tweet.

Mengambil Auth Token X → Install Dependency → Scrapping → Read Data hasil scrap

SCRAPPING

```
# 1. Twitter Auth Token
twitter_auth_token = "bc3ed24236285275482d46bcba75238572be6937"
```

Mengambil Auth Token X

Token ini adalah kunci autentikasi untuk mengakses data di X yang nanti digunakan oleh tweet-harvest agar bisa menjalankan pencarian tanpa API resmi.

SCRAPPING

Install Dependency

Menginstal semua komponen yang diperlukan seperti:

- Menginstall pandas untuk membaca file CSV.
- Menginstall tweet-harvest sebagai tool utama scraping.
- Menginstall Playwright + Chromium karena tweet-harvest butuh browser otomatis.
- Menginstall Node.js 20 karena tweet-harvest berjalan di Node.

```
# 2. Install Semua Komponen
!pip install pandas --quiet

# Install tweet-harvest
!npm install -g tweet-harvest

# Install Playwright + Chromium
!npx playwright install-deps
!npx playwright install chromium

# Install Node.js 20
!sudo apt-get update -y
!sudo apt-get install -y ca-certificates curl gnupg

!sudo mkdir -p /etc/apt/keyrings
!curl -fsSL https://deb.nodesource.com/gpgkey/nodesource-repo.gpg.key | \
    sudo gpg --dearmor -o /etc/apt/keyrings/nodesource.gpg

!echo "deb [signed-by=/etc/apt/keyrings/nodesource.gpg] \
https://deb.nodesource.com/node_20.x nodistro main" | \
    sudo tee /etc/apt/sources.list.d/nodesource.list

!sudo apt-get update
!sudo apt-get install -y nodejs
```

SCRAPPING

Menjalankan Scrapping

- Menentukan nama file CSV untuk menyimpan hasil scraping.
- Menentukan keyword pencarian dan jumlah tweet limit.
- Perintah npx tweet-harvest akan membuka browser otomatis dan mengambil tweet dari tab “Latest”.

```
# 3. Menjalankan Scraping
filename = 'df_kai_tumbler.csv'
search_keyword = 'tumbler kai lang:id'
limit = 2000

!npx -y tweet-harvest@2.6.1 \
    -o "{filename}" \
    -s "{search_keyword}" \
    --tab "LATEST" \
    -l {limit} \
    --token {twitter_auth_token}
```

SCRAPPING

Membaca & Mengecek Dataset

- Membaca file CSV yang dihasilkan oleh tweet-harvest.
- Mengecek jumlah tweet yang berhasil di-scrape.
- Menampilkan beberapa baris awal untuk memastikan data valid.

```
# 4. Membaca & Mengecek Dataset
import pandas as pd
filepath = f"tweets-data/{filename}" # Default path for tweet-harvest output
df = pd.read_csv(filepath)
print("Jumlah tweet yang di-scrape:", len(df))
df.head()
```

```
Jumlah tweet yang di-scrape: 908
```

PRE - PROCESSING

Preprocessing dilakukan untuk membersihkan teks dari elemen yang tidak relevan sehingga data menjadi lebih rapi, konsisten, dan siap digunakan model IndoRoBERTa. Dengan proses ini, kalimat yang dianalisis fokus pada makna inti tanpa gangguan seperti URL, mention, atau emoji.

PRE - PROCESSING

Tahapan:

1. **Mengubah teks menjadi lowercase**
   Menyamakan format kata agar model tidak membedakan huruf besar dan kecil.
2. **Menghapus HTML tags**
   Membersihkan elemen markup seperti , <br>, dan lainnya.
3. **Menghapus URL**
   Menghilangkan link seperti https://... atau www... yang tidak relevan untuk analisis.
4. **Menghapus mention (@username)**
   Membersihkan tag akun yang tidak memberikan konteks sentimen.
5. **Menghapus simbol hashtag (menyisakan kata)**
   Contoh: #tumbler → tumbler.
6. **Menghapus emoji**
   Mengurangi noise visual yang tidak dapat diproses BERT dalam bentuk asli.
7. **Menghapus penanda retweet (RT)**
   Membersihkan teks dari awalan seperti RT @user: agar konten lebih murni.
8. **Menghapus spasi berlebih**
   Merapikan teks agar tidak ada spasi ganda dan format lebih bersih.

PRE - PROCESSING

```python
import re
import string
import demoji

# Pastikan demoji aktif
demoji.download_codes()

# 1. Remove HTML tags
def remove_html(text):
    return re.sub(r'<.*?>', '', text)

# 2. Remove URLs
def remove_url(text):
    return re.sub(r'http\S+|www\.\S+', '', text)

# 3. Remove mentions (@user)
def remove_mention(text):
    return re.sub(r'@\S+', '', text)
```

```python
# 4. Remove hashtag symbol but keep the word
def remove_hashtag(text):
    return re.sub(r'#(\w+)', r'\1', text)

# 5. Remove emojis
def remove_emoji(text):
    return demoji.replace(text, repl="")

# 6. Remove retweet markers (RT)
def remove_rt(text):
    return re.sub(r'\brt[\s:]+', '', text)

# 7. Remove multiple spaces
def remove_extra_spaces(text):
    return re.sub(r'\s+', ' ', text).strip()
```

```python
# MASTER FUNCTION (khusus untuk BERT)
def preprocess_for_bert(text):
    text = str(text).lower()
    text = remove_html(text)
    text = remove_url(text)
    text = remove_mention(text)
    text = remove_hashtag(text)
    text = remove_emoji(text)
    text = remove_rt(text)
    text = remove_extra_spaces(text)

    return text
```

PRE - PROCESSING

Sebelum

1. Negeri ini sedang sakit 1 botol tumbler hilang 1 pegawai KAI dipecat tetapi hilangnya jutaan batang pohon yg menyebabkan kurang lebih ribuan rakyat meninggal tapi ada satupun yang dihukum. Negeri konoha memang beda nyawa rakyat lebih murah dari botol tumbler. #TakWaras https://t.co/3fOWT4AXLN

2. @antonyspin21 @Lullaby1237431 @dhemit_is_back @kukuh_irianto Nah sepemikiran Tumbler ketinggalan di mobil dia bilang ilang di KAI (dicuri)

3. @_riverheaven Narasi kancut. Mana ada pegawai KAI di pecat gegara tumbler hilang? Casing religius tp sebar fitnah. Memalukan. https://t.co/945qM0gYgf

4. @xcrot04 @dhemit_is_back @kukuh_irianto Dan sekarang belom jelas siapa yg ngumpetin itu tumbler. Mestinya KAI usut sampe tuntas

Contoh

Sesudah

1. negeri ini sedang sakit 1 botol tumbler hilang 1 pegawai kai dipecat tetapi hilangnya jutaan batang pohon yang menyebabkan kurang lebih ribuan rakyat meninggal tapi ada satupun yang dihukum. negeri konoha memang beda nyawa rakyat lebih murah dari botol tumbler. takwaras

2. nah sepemikiran tumbler ketinggalan di mobil dia bilang ilang di kai (dicuri)

3. narasi kancut. mana ada pegawai kai di pecat gegara tumbler hilang? casing religius tapi sebar fitnah. memalukan.

4. dan sekarang belom jelas siapa yang ngumpetin itu tumbler. mestinya kai usut sampai tuntas

Feature Extraction

Teks → vector (embedding)

Dikarenakan Metode klasifikasi yang digunakan menggunakan transformers yaitu IndoRoBERTa, proses *feature extraction* terjadi secara otomatis di dalam arsitektur Transformers tanpa memerlukan teknik manual seperti TF-IDF atau word2vec. Teks Terlebih dahulu ditokenisasi menjadi subword oleh SentencePiece, lalu setiap token diubah menjadi embedding numerik yang telah dipelajari saat pre-training. Embedding ini kemudian diproses melalui lapisan bidirectional self-attention. Hal ini memungkinkan model memahami konteks seluruh kalimat. Hasil akhirnya adalah representasi kontekstual (hidden states), di mana vektor token [CLS] digunakan sebagai fitur utama untuk klasifikasi. Dengan demikian, IndoRoBERTa mengekstraksi fitur secara end-to-end dan langsung menyediakan representasi semantik untuk tugas klasifikasi.

```
from transformers import AutoTokenizer, AutoModelForSequenceClassification, pipeline
from transformers import TrainingArguments, Trainer
```

Klasifikasi

Proses klasifikasi ini menggunakan model IndoRoBERTa yang sudah dilakukan fine tuning dari website huggingface dengan model yang digunakan yaitu “w11wo/indonesian-roberta-base-sentiment-classifier". Berikut ini merupakan beberapa library dan module yang digunakan dalam menggunakan model ini, yaitu :

```
from transformers import AutoTokenizer, AutoModelForSequenceClassification, pipeline
from transformers import TrainingArguments, Trainer
from sklearn.metrics import classification_report
from datasets import Dataset
import pandas as pd
import torch
```

Klasifikasi

Selanjutnya yaitu menjalankan model klasifikasi, pada tahap ini dilakukan juga tokenisasi dalam tahap klasifikasi menggunakan fungsi “AutoTokenizer”. Setelah itu dilakukan klasifikasi menggunakan fungsi “pipeline” yang berguna untuk menyederhanakan proses pemanggilan model, tokenisasi, prediksi, dan decoding dalam satu fungsi. Label_map berfungsi untuk menentukan output klasifikasi yang digunakan jika hasil yang ditampilkan tidak sama persis seperti model Indo RoBERTa yang digunakan namun masih memiliki makna yang sama.

```
pretrained= "w11wo/indonesian-roberta-base-sentiment-classifier"

model = AutoModelForSequenceClassification.from_pretrained(pretrained)
tokenizer = AutoTokenizer.from_pretrained(pretrained)

labeler = pipeline("sentiment-analysis", model=model, tokenizer=tokenizer)

label_map = {'positive': 'positif', 'neutral': 'netral', 'negative': 'negatif'}
```

Klasifikasi

Selanjutnya melakukan klasifikasi menggunakan data teks yang sudah siap menggunakan labeler, yaitu pipeline dari model dan tokenizer yang digunakan. Pada proses klasifikasi tersebut, diterapkan juga perubahan output klasifikasi (label_map) agar sesuai dengan yang kita inginkan. Dapat dilihat juga beberapa contoh output yang dihasilkan menggunakan fungsi tersebut.

```
preds = labeler(df1["clean_text"].tolist())

df1["label"] = [label_map[p["label"]] for p in preds]
df1.head()
```

clean_text	label
negeri ini sedang sakit 1 botol tumbler hilang...	negatif
gimana pak ? sudah layak belum di pecat ni mas...	negatif
ups maaf kalau gajelas tadi! ini x wrapped 202...	netral
ī¸□ x wrapped 2025 untuk cawdleu! - total post...	netral
hai! ini twitter wrapped 2025-mu berdasarkan a...	positif

EVALUASI

Evaluasi dilakukan dengan membandingkan hasil prediksi sentimen dari model IndoRoBERTa terhadap 20% data yang telah dilabeli secara manual, untuk melihat seberapa akurat model dalam mengklasifikasikan komentar. Hasil classification report dan confusion matrix menunjukkan performa model dalam mengenali kelas negatif, netral, dan positif.

```python
from sklearn.metrics import classification_report, confusion_matrix
import pandas as pd

# Get true labels from the manually labeled dataset
y_true = dg['Sentimen_2']

# Generate predictions for the same texts that were manually labeled
preds_for_labeled_data = labeler(dg['clean_text'].tolist())
y_pred = [label_map[p["label"]] for p in preds_for_labeled_data]

# Classification Report (Precision, Recall, F1, Accuracy)
print(classification_report(y_true, y_pred))
```

	precision	recall	f1-score	support
negatif	0.78	0.93	0.85	75
netral	0.85	0.79	0.81	70
positif	0.73	0.38	0.50	21
accuracy			0.80	166
macro avg	0.78	0.70	0.72	166
weighted avg	0.80	0.80	0.79	166

Kode ini mengambil label manual sebagai y_true dan label prediksi dari model sebagai y_pred, kemudian menggunakan fungsi classification_report() untuk menghitung precision, recall, dan F1-score tiap kelas.

Model IndoRoBERTa mampu mengenali komentar negatif dan netral dengan baik, tetapi masih kurang akurat pada komentar positif. Secara keseluruhan, model mencapai akurasi sekitar 80%, menunjukkan performa yang cukup baik dalam melakukan klasifikasi dara

EVALUASI

CONFUSION MATRIKS

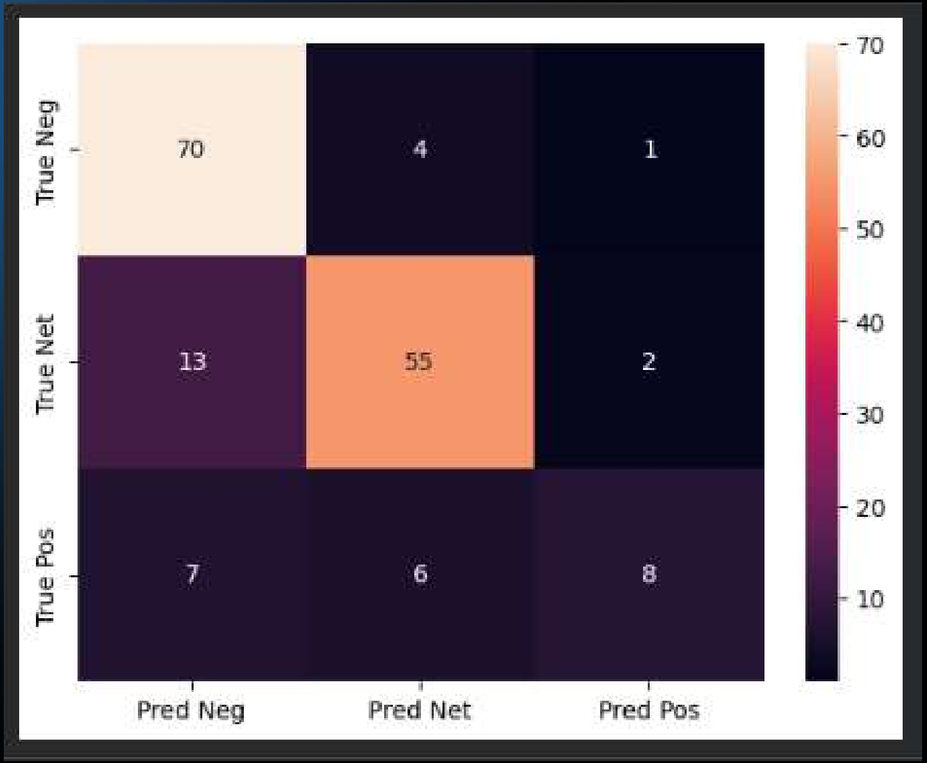


```
import seaborn as sns
import matplotlib.pyplot as plt

sns.heatmap(cm, annot=True, fmt="d",
            xticklabels=['Pred Neg','Pred Net','Pred Pos'],
            yticklabels=['True Neg','True Net','True Pos'])
plt.show()
```

Confusion matrix memperlihatkan bagaimana model salah atau benar memprediksi setiap kelas sentimen; semakin tinggi angka diagonal utama (benar), semakin baik performa model dalam membedakan komentar negatif, netral, dan positif.

EVALUASI

clean_text	Sentimen_2	label
kasus viral tumbler ini soal penumpang kai yan...	netral	negatif
konteksnya seorang penumpang lupa bawa tumbler...	netral	negatif
potret kebersamaan argi dengan anita dan alvin...	positif	netral
si anita kehilangan tumbler k sampai laporan k...	negatif	netral
tumbler tuku yang hilang itu harganya resmi rp...	netral	negatif

```
dg['label'] = y_pred
df_error = dg[dg['Sentimen_2'] != dg['label']]
df_error.head()
```

Data tersebut menampilkan beberapa data pada proses evaluasi yang hasil pelabelan manual dengan yang dihasilkan oleh model berbeda dan mengurangi tingkat akurasi model klasifikasinya.

ANALISIS SENTIMEN

Distribusi Sentimen

Kategori	Persentase	Interpretasi
Negatif	58.00%	Sentimen dominan; menunjukkan publik sangat kritis terhadap isu yang diangkat.
Netral	34.60%	Proporsi cukup besar; menunjukkan banyak pengguna fokus pada penyebutan fakta atau informasi.
Positif	7.40%	Sentimen minoritas; menunjukkan adanya sedikit apresiasi atau seruan untuk menyelesaikan polemik.

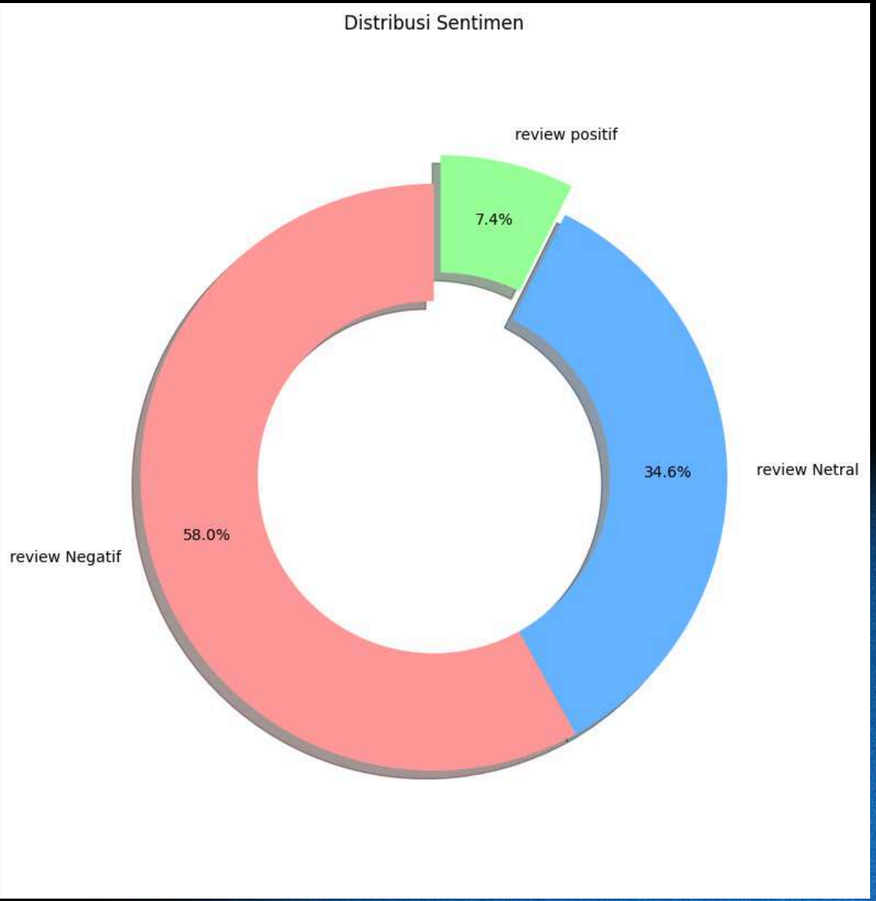

ANALISIS SENTIMEN

WordCloud

Analisis sentimen dilakukan untuk memahami reaksi publik terhadap kasus viral kehilangan tumbler yang melibatkan penumpang dan KAI. Untuk mengetahui tema yang dominan di tiap emosi, digunakan **WordCloud yaitu visualisasi frekuensi kata** yang memperlihatkan isu-isu paling sering dibicarakan. WordCloud membantu **mengidentifikasi fokus perbincangan, sumber emosi, dan arah opini masyarakat.**

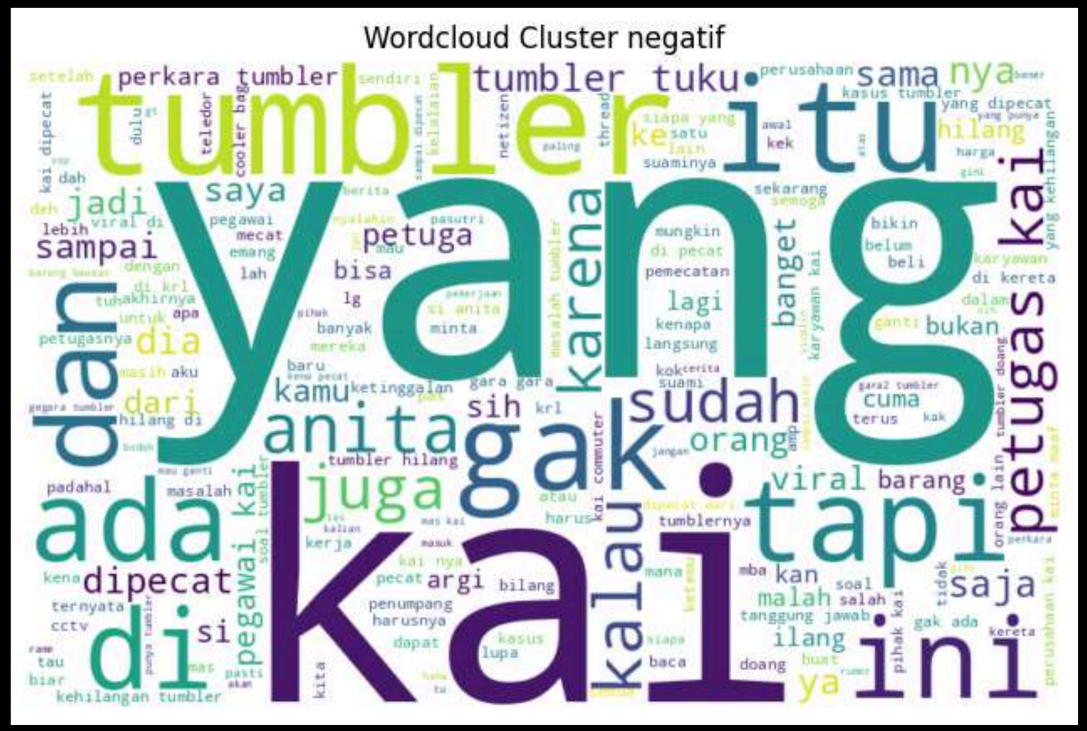

- **Fokus Utama Kasus:** Sentimen negatif secara jelas terpusat pada KAI dan insiden Tumbler, menunjukkan perusahaan menjadi target utama kritik.
- **Isu Paling Menonjol (Kritik):** Kritik didominasi oleh isu Pemecatan atau sanksi yang dikenakan terhadap Pegawai atau Karyawan. Ukuran kata 'dipecat' sangat besar, mencerminkan adanya persepsi ketidakadilan atau hukuman yang berlebihan.
- **Aktor dan Kejadian:** Kata 'Anita' (merujuk pada pihak terkait) dan kata 'hilang' atau 'kehilangan' muncul, mengaitkan sentimen negatif langsung pada pihak-pihak yang terlibat dan kejadian hilangnya barang.
- **Kesimpulan Sentimen:** Secara keseluruhan, wordcloud menunjukkan tingginya tingkat kekecewaan dan kritik terhadap way of handling kasus oleh KAI, khususnya yang berkaitan dengan nasib SDM mereka.

ANALISIS SENTIMEN

WordCloud

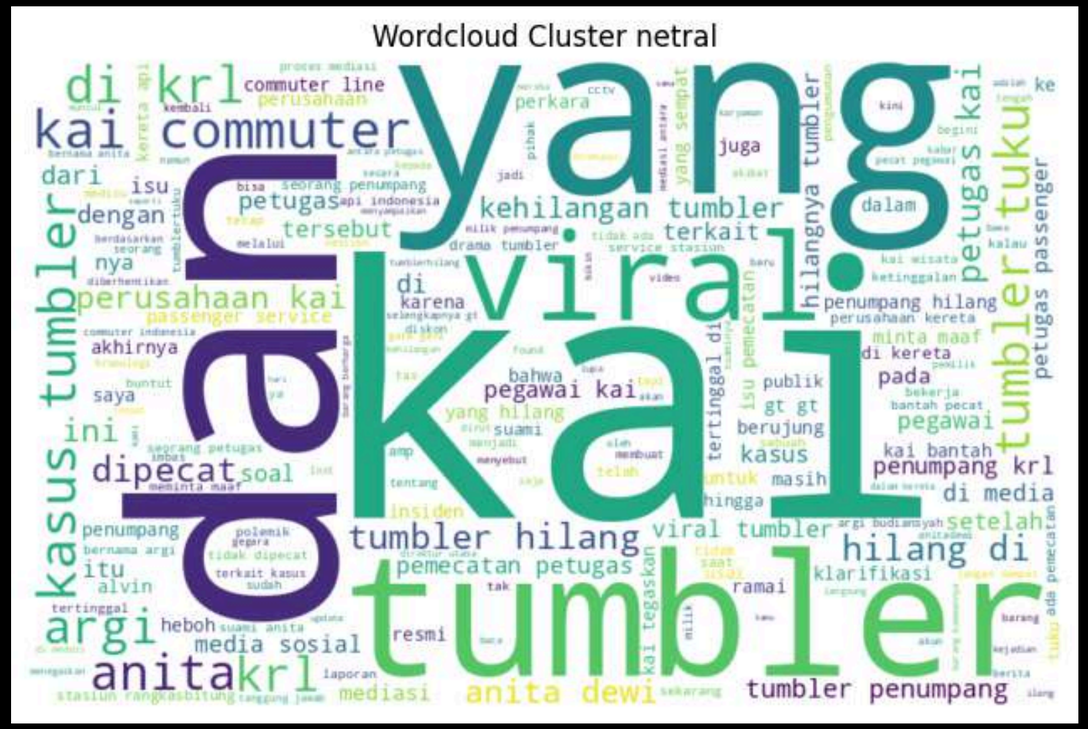

- **Fokus utama:** Kata kunci utama yang berukuran paling besar adalah KAI, Tumbler, Yang, dan Itu, yang menandakan bahwa sebagian besar percakapan netral berfokus pada penyebutan fakta dan informasi seputar entitas dan objek yang terlibat dalam insiden tersebut.

- **Kesimpulan Sentimen:** Sentimen netral umumnya muncul dalam bentuk pelaporan fakta dan penyebaran informasi tentang insiden (siapa melakukan apa, dan di mana). Netizen lebih banyak menyebutkan nama, jabatan, objek, dan status kasus, tanpa mengekspresikan emosi atau menilai secara moral.

ANALISIS SENTIMEN

WordCloud

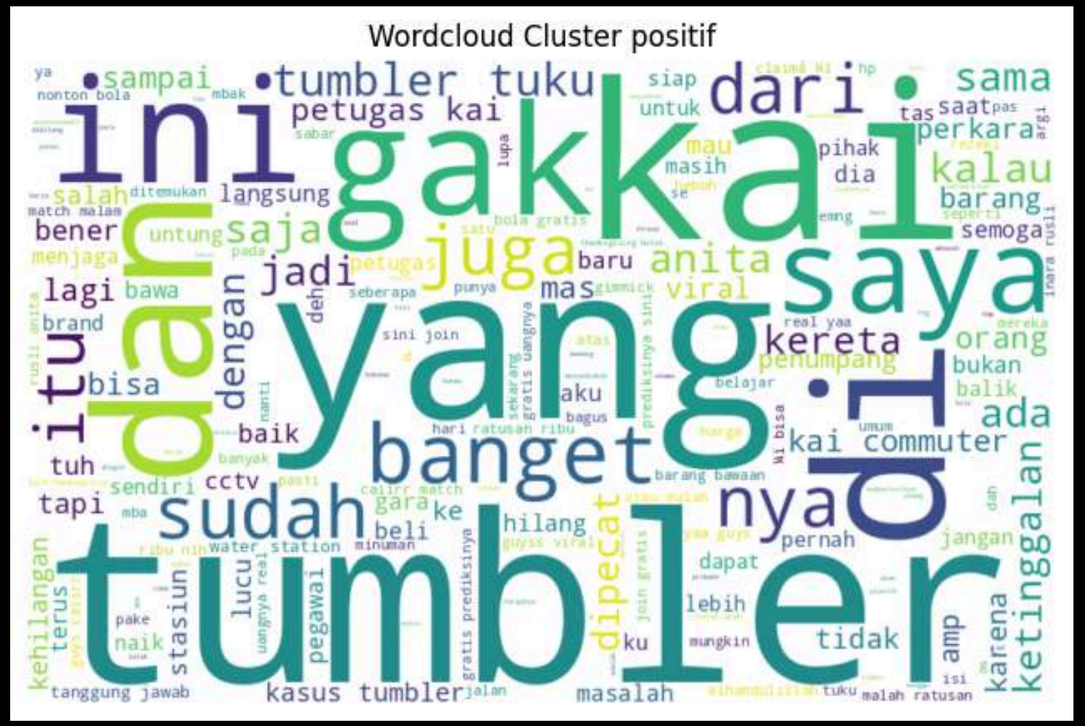

- **Fokus Informasi:** Kata kunci utama yang berukuran paling besar adalah KAI, Tumbler, Yang, dan Itu, yang menandakan bahwa sebagian besar percakapan positif berfokus pada penyebutan fakta dan informasi seputar entitas dan objek yang terlibat dalam insiden tersebut.

- Kata Gak/Gak/Gak/Gak (sering muncul dalam konteks dialek, kemungkinan besar "gak/enggak apa-apa" atau "gak usah diseriusin") dan Sudah menonjol. Ini bisa diinterpretasikan sebagai seruan untuk mengakhiri polemik, merelakan, atau menganggap kasus sudah selesai atau tidak perlu diperpanjang.

- Kata Bisa, Tanggung Jawab, dan Baik hadir. Ini mencerminkan apresiasi publik terhadap upaya pertanggungjawaban atau respons yang baik (meskipun mungkin dari pihak tertentu) yang terjadi selama atau setelah insiden.

- **Kesimpulan Sentimen:** Sentimen positif berfokus pada rasa lega, solusi damai, dan apresiasi (walau minoritas) terhadap upaya penyelesaian atau tindakan baik yang dilakukan. Terdapat dorongan untuk mengakhiri drama dan move on dari kasus ini.

ANALISIS SENTIMEN

Bigram/Trigram pada Setiap Sentimen

"N-gram digunakan untuk melihat gabungan kata yang sering muncul berurutan sehingga membantu mengidentifikasi topik atau isu dominan pada setiap kategori sentimen."

Positif

Frasa	Frekuensi
tumbler tuku	12
petugas kai	9
kai commuter	8
mas kai	5
di stasiun	4

Walaupun jumlah positif lebih sedikit, komentar positif mencakup apresiasi kepada petugas KAI dan topik terkait layanan.

Netral

Frasa	Frekuensi
kai commuter	58
kasus tumbler	57
di krl	52
tumbler tuku	49
tumbler hilang	47

Sentimen netral berisi frasa informatif seperti lokasi (KRL) dan kronologi kehilangan tumbler. Komentar netral lebih bersifat deskriptif.

Negatif

Frasa (2–3 kata)	Frekuensi
petugas kai	100
tumbler tuku	96
pegawai kai	60
perkara tumbler	58
kehilangan tumbler	43

Sentimen negatif didominasi oleh frasa terkait petugas KAI, kehilangan tumbler, dan isu tanggung jawab, menunjukkan ketidakpuasan publik terhadap handling kasus ini.

THANK YOU

www.reallygreatsite.com